Практичне заняття 3.

Тема: Метод опорних векторів в системах машинного навчання

Метод опорних векторів (SVM) є потужним алгоритмом для класифікації та регресії, що заснований на ідеї знаходження оптимальної розділяючої гіперплощини між класами. Таким чином, SVM призначений для вирішення задач класифікації та регресії. В основі методу лежить поняття гіперплощини, що найкращим чином розділяє класи в просторі ознак.

Основним завданням SVM є знаходження гіперплощини, яка максимізує відстань між найближчими до неї точками кожного класу, відомих як опорні вектори. Для нелінійної класифікації SVM використовує ядро, яке перетворює вхідний простір ознак у простір більш високої розмірності, де можливо знайти лінійно розділювальну гіперплощину. У випадку регресії, SVM знаходить гіперплощину, що мінімізує помилку моделі, з урахуванням штрафу за відхилення точок від функції регресії.

Особливості методу

- Висока точність: SVM широко використовується у багатьох областях через його здатність до класифікації з високою точністю.

- Ефективність у високорозмірних просторах: SVM ефективно працює навіть у випадку, коли кількість ознак є значною.

- Чутливість до параметрів: налаштування параметрів ядра і штрафних параметрів може впливати на результат моделі.

- Обмеженість інтерпретації: SVM не завжди забезпечує інтерпретовані результати через складність гіперплощини у високорозмірних просторах.

Для використання методу опорних векторів математично ми шукаємо гіперплощину у просторі ознак X, яка задовольняє умову:

$$w^T x + b = 0$$

де w - вектор вагів, який визначає орієнтацію гіперплощини, b - зсув (або зсув відносно початку координат), а x - вектор ознак.

Класифікація об'єкта полягає в тому, щоб перевірити, по яку сторону від цієї гіперплощини він знаходиться. Це визначається значенням виразу $w^T x + b = 0$ – якщо воно більше за 0, то об'єкт належить до одного класу, якщо менше - до іншого.

У випадку лінійно нероздільних даних, ми можемо використовувати ядро $K\ (x,\ x^{'})$, яке перетворює дані у вищорозмірний простір, де вони можуть бути розділені гіперплощиною. Основна формула для розрахунку функції рішення залишається такою ж, але ознаки замінюються їхними відповідними значеннями у вищорозмірному просторі.

Основною задачею при тренуванні SVM є знаходження оптимальних значень вагів w і зсуву b, які максимізують відстань між гіперплощиною і найближчими до неї точками кожного класу. Ця відстань називається шириною коридору (margin) і визначається як відстань від опорних векторів до гіперплощини.

Таким чином, ця задача формулюється як оптимізаційна задача з обмеженнями, яка полягає в максимізації ширини коридору за умови правильної класифікації навчальних прикладів.

Наведемо приклад реалізації задачі класифікації. У цьому коді ми використовуємо бібліотеку `scikit-learn`, яка містить реалізацію SVM за допомогою класу `svc`. Ми завантажуємо датасет ірисів, розділяємо його на тренувальний і тестовий набори, створюємо класифікатор SVM з лінійним

ядром (`kernel='linear'`), тренуємо його на тренувальних даних, робимо прогнози для тестових даних і обчислюємо точність прогнозів.

```
# Імпортуємо бібліотеки
import numpy as np
from sklearn import datasets
from sklearn.model_selection import train_test_split
from sklearn.svm import SVC
from sklearn.metrics import accuracy_score

# Завантажуємо дані (наприклад, датасет про іриси)
iris = datasets.load_iris()
X = iris.data
y = iris.target

# Розділяємо дані на тренувальні та тестувальні набори
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Створюємо класифікатор SVM
clf = SVC(kernel='linear')

# Тренуємо класифікатор на тренувальних даних
clf.fit(X_train, y_train)

# Прогнозуємо класи для тестувальних даних
y_pred = clf.predict(X_test)

# Обчислюємо точність прогнозу
accuracy = accuracy_score(y_test, y_pred)
print("Accuracy:", accuracy)
```

Завдання: реалізувати алгоритм методу опорних векторів, використавши один з датасетів https://www.kaggle.com/datasets?search=security, оцінити точність та фактори, від яких вона може залежати на прикладі обраного датасету.